

Utilizando Redes Neurais Convolucionais para Automatizar a Detecção de Defeitos Físicos em PCBs na Indústria 4.0

Fábio S. D. Silva * Tiago R. D. Sá * Kaio A. S. Lima *
Rodrigo C. D. Freitas * Karoline S. Pereira *
Ramayana A. M. Júnior * Neide F. Alves * Mario G. Carvalho *
Lucas G. Flores *

* Universidade do Estado do Amazonas,
Instituto Federal do Amazonas
Manaus

{fssilva, trs.eng17, kasl.eng19, rcfreitas, ksp.mtr18, rajunior,
nfalves}@uea.edu.br,
{carvalho16car, lgomesflores74}@gmail.com

Abstract: This article proposes the use of Convolutional Neural Networks (CNNs) for the detection of physical defects in PCBs. Three canonical CNN architectures were evaluated: VGG19, MobileNet, and InceptionV3. Performance was measured using the accuracy metric and the defect detection model that showed the best performance, with an accuracy of approximately 98.12%, was the MobileNet model. This study provides a solid foundation for the development of automated defect detection systems for the information technology industry and contributes to the implementation of Industry 4.0.

Resumo: Este artigo propõe o uso de Redes Neurais Convolucionais (CNNs) para a detecção de defeitos físicos em PCBs. Foram avaliadas três arquiteturas de CNNs canônicas: VGG19, MobileNet e InceptionV3. O desempenho foi medido utilizando a métrica de acurácia e o modelo de detecção de defeitos que apresentou o melhor desempenho, com uma acurácia de aproximadamente 98,12%, foi o modelo da MobileNet. Este estudo fornece uma base sólida para o desenvolvimento de sistemas de detecção de defeitos automatizados para a indústria de tecnologia da informação e contribui para aplicar a Indústria 4.0.

Keywords: Convolutional Neural Networks; defect detection; memory modules; VGG19; MobileNet; InceptionV3; accuracy; Industry 4.0.

Palavras-chaves: Redes Neurais Convolucionais; detecção de defeitos; módulos de memória; PCB; VGG19; MobileNet; InceptionV3; acurácia; Indústria 4.0.

1. INTRODUÇÃO

A automatização de processos de inspeção visual tem sido um crescente tema de pesquisa na indústria de tecnologia da informação, pois permite aumentar a eficiência e precisão, reduzir custos e melhorar a qualidade do produto. No caso específico da indústria de PCBs (*Printed Circuit Boards - PCBs*), a detecção de defeitos físicos é um processo crítico que é normalmente automatizado nas etapas iniciais do processo de fabricação de PCBs. No entanto, é importante ressaltar que, para a fase de envio dos produtos aos clientes, a inspeção pode ocorrer de forma manual por operadores humanos. Essa abordagem manual apresenta várias desvantagens, como o potencial de erros humanos, a fadiga dos operadores e a limitada velocidade de processamento. Para superar esses desafios, tem-se recorrido ao uso da Inteligência Artificial (IA) para automatizar esses processos. Em particular, as Redes Neurais Convolucionais - *Convolutional Neural Networks (CNNs)* têm mostrado uma excelente capacidade para a detecção de defeitos em imagens (Kim et al., 2021; Xin et al., 2021).

Este artigo apresenta um estudo que avaliou o desempenho de três arquiteturas canônicas de *CNNs* como *VGG19*, *MobileNet* e *InceptionV3* para a detecção de defeitos físicos em imagens PCBs. O objetivo é fornecer uma base sólida para o desenvolvimento de sistemas de detecção de defeitos automatizados para a indústria de eletrônicos e contribuir para aplicar a Indústria 4.0. Esse artigo está estruturado da seguinte forma: a segunda seção, Revisão da Literatura, apresenta os estudos existentes relacionados ao tema, especialmente sobre o uso de *CNNs* e outras técnicas de IA para automatizar a detecção de defeitos em imagens. A terceira seção, Métodos e Materiais, descreve detalhadamente os métodos utilizados no estudo, incluindo a descrição do conjunto de dados, método de detecção de defeitos proposto e as ferramentas utilizadas. A quarta seção, Resultados, apresenta e discute os resultados obtidos, incluindo a comparação do desempenho das diferentes arquiteturas canônicas de *CNNs* avaliadas. A quinta seção, Conclusão, sintetiza os principais resultados e suas implicações, além de sugestões para futuros estudos e possíveis aplicações na

indústria. Por fim, a sexta seção, Referências, apresenta a lista de referências bibliográficas utilizadas no artigo.

2. REVISÃO DA LITERATURA

Essa seção versa sobre Inspeção Visual de Produtos Baseada em Inteligência Artificial, o uso de *CNNs*, a Abordagem de ML (*Machine Learning*) Supervisionado e as técnicas pré-processamento que foram empregadas nesse trabalho para melhorar o desempenho dos modelos, tais como (*Data Augmentation*) e *Dropout*.

2.1 Redes Neurais Convolucionais (CNNs)

As *CNNs* constituem uma classe de algoritmos de aprendizado de máquina com grande eficácia para a classificação de imagens e reconhecimento de padrões. Essas redes se baseiam na ideia de que as camadas de neurônios interconectados, conhecidas como camadas de convolução, podem ser utilizadas para extrair características relevantes das imagens (Shen et al., 2017).

Algumas das arquiteturas de *CNNs* mais populares incluem *VGG19*, *MobileNet* e *InceptionV3*, que são amplamente utilizadas em diversas tarefas de classificação de imagens, e são as arquiteturas utilizadas no estudo mencionado no artigo.

2.2 Inspeção Visual de Produtos Baseada em Inteligência Artificial

A inspeção visual de produtos é uma tarefa crítica na indústria de manufatura, pois garante a qualidade dos produtos e evita problemas de segurança e garantia (Arinez et al., 2020). No entanto, a inspeção visual manual é uma tarefa tediosa e suscetível a erros humanos, o que pode resultar em altos custos e ineficiência.

Entre as técnicas de IA utilizadas na inspeção visual de produtos, as *CNNs* tem se destacado como uma abordagem eficaz para a detecção de defeitos (Qi et al., 2020). De acordo com o artigo proposto por Arinez et al. (2020), “as *CNNs* têm mostrado desempenho superior para a detecção de defeitos superficiais em produtos industriais, devido à sua capacidade de aprender características relevantes das imagens dos produtos e lidar com grandes quantidades de dados”.

2.3 Abordagem de ML Supervisionado

A abordagem de Aprendizagem de Máquina Supervisionada é uma técnica amplamente utilizada para resolver problemas de classificação e reconhecimento de padrões (Qi et al., 2020). Ela é baseada no princípio de fornecer ao algoritmo um conjunto de registros rotulados de entrada e saída, a fim de permitir que o algoritmo aprenda a fazer previsões sobre novos dados. Um registro pode ser, por exemplo, uma imagem.

2.4 Pré-processamento

O pré-processamento de imagens é uma etapa importante no treinamento de modelos de *CNNs*. Ele inclui técnicas

para ajustar o tamanho, cor, contraste e brilho das imagens, bem como para normalizar os dados. Além disso, técnicas como *Data Augmentation* podem ser usadas para aumentar o tamanho do conjunto de dados e evitar *overfitting*.

Algumas técnicas comuns de pré-processamento que podem melhorar a acurácia de um modelo de *CNN* para classificação de imagens incluem: redimensionamento e normalização de imagem; *Data Augmentation* (Arun Pandian et al., 2019; Kim and Bae, 2020), *Dropout* (Srivastava et al., 2014; Gal and Ghahramani, 2016), filtros para remoção de ruído, centralização e alinhamento, e transformações de espaço de cores são técnicas comuns de pré-processamento que podem melhorar a acurácia de um modelo de *CNN* para classificação de imagens (Reinhard et al., 2002). Nesse trabalho foi empregado o filtro para ajustar o contraste e o brilho das imagens.

Os filtros são, normalmente, empregados para ajudar a destacar as características importantes na imagem e a torná-las mais fáceis de serem detectadas pelo modelo (Reinhard et al., 2002). Algumas das técnicas incluem: (i) Ajuste de brilho e contraste linear: ajusta o brilho e o contraste da imagem multiplicando cada pixel pela mesma constante e adicionando outra constante; (ii) Equalização de histograma: ajusta o contraste da imagem redistribuindo os valores de pixels para cobrir o intervalo total disponível; Filtro gamma: ajusta o brilho e o contraste da imagem aplicando uma transformação logarítmica ou potência em cada pixel.

3. TRABALHOS RELACIONADOS

IA e *CNNs* têm sido usadas para automatizar processos de inspeção e detecção de defeitos em imagens. Embora ainda seja um tema de pesquisa recente, já existem estudos sobre o uso de *CNNs* para detecção de defeitos em imagens de PCBs.

Um exemplo é o trabalho de Kim et al. (2021) no qual foi utilizado uma *CNN* do tipo *Autoencoder* para detectar defeitos na superfície de placas de circuito impresso. Os autores mostraram que a *CNN* foi capaz de detectar com precisão os defeitos e superou as técnicas de inspeção tradicionais.

Outro exemplo é o trabalho de Xin et al. (2021) no qual foi utilizado o algoritmo *YOLOv4* baseado em *CNN* também para detectar defeitos em placas de circuito impresso. Os autores mostraram que a *YOLOv4* conseguiu detectar alguns tipos de defeitos como componente faltando ou invertido, mas que a solução proposta precisa passar por mais experimentos visando avaliar melhor a sua eficiência.

O estudo de Iwahori (2017) propõe um método para detecção e classificação de defeitos em placas de circuito eletrônico, utilizando pontos-chave extraídos da imagem da placa para cortar imagens em *patches*, que são alimentados na *CNN AlexNet*. O objetivo é distinguir entre defeitos problemáticos e não-defeitos.

Além desses estudos, outros estudos mostram que o uso de *CNNs* para a detecção de defeitos em imagens de PCBs é uma abordagem promissora e que já existem alguns estudos que mostram resultados positivos (Shiina et al.,

2018; Hou et al., 2017; Song et al., 2021). A pesquisa nessa área ainda é incipiente e há ainda muito espaço para o desenvolvimento de novos métodos e aplicações.

O estudo descrito neste artigo se diferencia dos trabalhos supracitados por avaliar o desempenho de três arquiteturas canônicas de CNNs, isto é, *VGG19*, *MobileNet* e *InceptionV3*. A maioria dos trabalhos anteriores não avaliou nenhuma das CNNs experimentadas nesse trabalho, empregaram apenas uma arquitetura de CNN para a detecção de defeitos em imagens de PCBs ou combinaram CNNs. Além disso, esse estudo se diferencia por aplicar filtros para ajustar o contraste e brilho das imagens usadas para o treinamento, avaliação e testes dos modelos de CNNs avaliados no trabalho. Isso proporciona uma base sólida para o desenvolvimento de sistemas de detecção de defeitos automatizados para a indústria de tecnologia da informação e contribui para aplicar a Indústria 4.0.

4. MÉTODOS E MATERIAIS

Esta seção descreve a abordagem proposta que será utilizada para detecção de defeitos físicos em imagens de PCBs, as arquiteturas de CNNs que foram avaliadas, conjunto de dados empregado e o processo de treinamento dos modelos.

4.1 Abordagem de Inspeção de PCBs para Detecção de Defeitos

O uso de CNN para inspeção de defeitos físicos em PCBs é uma abordagem eficaz para detectar e identificar defeitos. Através de um processo de pré-processamento de imagens, a CNN é treinada com uma grande quantidade de imagens de PCBs, tanto com quanto sem defeitos físicos, para que possa aprender a reconhecer padrões e características associadas a módulos com defeitos físicos. Com isso, quando uma nova imagem é inserida no sistema, a CNN pode classificá-la como tendo ou não um defeito físico com elevada precisão, acionando uma série de ações, como a rejeição do módulo ou a marcação do módulo para inspeção adicional. Além disso, o sistema pode ser configurado para aprender continuamente a partir de novos dados, permitindo que ele se adapte e melhore com o tempo.

4.2 Arquiteturas de CNNs

Neste estudo, foram avaliadas quatro arquiteturas de CNNs populares para o sistema de detecção de defeitos em imagens de PCBs: *VGG19*, *MobileNet*, e *InceptionV3*. Cada uma dessas arquiteturas possui suas próprias vantagens e limitações, que serão discutidas a seguir.

A *VGG19* é uma arquitetura de CNN desenvolvida por Simonyan and Zisserman (2015) e foi utilizada para vencer a competição *ImageNet* 2014. Ela é conhecida por sua alta precisão, mas também é conhecida por ser uma arquitetura de alta complexidade computacional. A *MobileNet* é uma arquitetura de CNN desenvolvida por Howard et al. (2017) com o objetivo de ser usada em dispositivos móveis com limitações de recursos. Ela é conhecida por sua eficiência computacional, mas também é conhecida por ter menor precisão em comparação com outras arquiteturas de CNN. Por fim, a *InceptionV3* é uma arquitetura de CNN desenvolvida por Szegedy et al. (2016) e foi utilizada



Figura 1. Plataforma para captura de Imagens.

para vencer a competição *ImageNet* 2015. Ela é conhecida por sua alta precisão e eficiência computacional. A CNN criada especificamente para este estudo foi desenvolvida com base em uma combinação das arquiteturas *VGG19* e *InceptionV3*, com o objetivo de obter uma boa precisão e eficiência computacional.

Ressalta-se que a *VGG19* é considerada uma das redes neurais mais profundas e complexas entre as três mencionadas. Ela tem 19 camadas de processamento, enquanto que *MobileNet* tem apenas 30 camadas e *InceptionV3* tem apenas 159 camadas. Além disso, a *VGG19* utiliza filtros de convolução de tamanhos 3x3 e 2x2, o que permite a extração de características mais complexas e detalhadas das imagens.

4.3 Conjunto de dados

Para o treinamento, avaliação e testes dos modelos de CNNs empregados na detecção de defeitos em PCBs, foram utilizadas 4804 imagens de 456x193 pixels, classificadas em duas classes: Good e Bad. As imagens foram capturadas em alta resolução (5198 x 3462 pixels) por meio de uma câmera industrial com suporte e fonte de luz baseada em anel de LED, utilizando lente industrial com zoom sem distorção ajustável (6-12mm, f1.6).

Os recortes destacados em vermelhos são os que apresentam algum tipo de defeito. Já os recortes destacados em verde são os que não apresentam defeitos. As razões para o emprego dessa abordagem são, especialmente, a redução do tempo e do custo computacional para o treinamento do modelo de aprendizagem de máquina profundo, além de viabilizar a aquisição de imagens com exemplos diversos de defeitos físicos.

O conjunto de dados disponível foi dividido aleatoriamente seguindo o critério de validação *hold-out* (Maleki et al., 2020). Nesse cenário, 80% dos dados foram usados para a fase de treino, 10% para validação e, consequentemente, 10% para teste. A Figura 3 apresenta alguns recortes da imagem original do PCB que foram empregadas no procedimento de treinamento e validação dos modelos.

Na Figura 3, há exemplos de recortes de imagens do PCB rotulados como "Bad" ou "Good". Os recortes "Bad" possuem




Figura 2. Imagem de PCB.




Figura 3. Imagens do Conjunto de Dados.

danos físicos, como soldas defeituosas, rachaduras ou fissuras, danos mecânicos ou na superfície. Já os recortes "Good" não possuem danos físicos. Foram usadas 4804 imagens para o treinamento, 2000 rotuladas como "Bad" e 1836 como "Good", 768 imagens para validação, igualmente divididas entre as duas classes, e 200 imagens para teste, também divididas equitativamente entre as duas classes.

4.4 Treinamento de modelos

Para treinar os modelos de CNNs, foi utilizado o *framework TensorFlow* (Pang et al., 2020). O treinamento dos modelos foi realizado em um servidor robusto que possui um processador Intel Core i7, 32 GB de RAM, SSD de 256 MB e placa gráfica com 11GB de GPU, o que viabilizou a aceleração em hardware do treinamento

Foram utilizados neste trabalho dois otimizadores populares na otimização de redes neurais: o RMSProp, proposto por Tieleman et al. (2012), e o Adam, proposto por Kingma and Ba (2017). Ambos são baseados na descida de gradiente estocástico, mas possuem diferenças importantes. O Adam combina a descida de gradiente estocástica com o Momentum, mantendo duas médias móveis e ajustando dinamicamente a taxa de aprendizado. Já o RMSProp utiliza uma constante de esquecimento para esquecer gradualmente os gradientes mais antigos, divide a taxa de aprendizado pelo desvio padrão dos gradientes ao quadrado, permitindo uma adaptação mais precisa às diferentes escalas de parâmetros.

É importante mencionar que a acurácia de uma rede neural também pode ser aumentada através da otimização de hiperparâmetros e da realização de ajustes finos. Dessa forma, foram treinados um número total de 12 modelos com diferentes configurações de parâmetros e hiperparâ-

mentos. A etapa de treinamento de todos os modelos demorou aproximadamente 20 horas. As configurações de treinamento de CNNs são apresentadas na tabela a seguir.

Tabela 1. Configurações para treinamento de CNNs.

CNN	Config.	Otim.	Augm.	Drop.	Filtro
VGG19	11	Adam	Não	Não	Não
VGG19	12	Adam	Sim	Sim	Sim
MobileNet	11	Adam	Não	Não	Não
MobileNet	12	Adam	Sim	Sim	Sim
InceptionV3	11	Adam	Não	Não	Não
InceptionV3	12	Adam	Sim	Sim	Sim
VGG19	21	RMSProp	Não	Não	Não
VGG19	22	RMSProp	Sim	Sim	Sim
MobileNet	21	RMSProp	Não	Não	Não
MobileNet	22	RMSProp	Sim	Sim	Sim
InceptionV3	21	RMSProp	Não	Não	Não
InceptionV3	22	RMSProp	Sim	Sim	Sim

5. RESULTADOS

Esta seção apresenta e discute dos resultados obtidos, incluindo a comparação do desempenho das diferentes arquiteturas de CNNs avaliadas. A fase de teste foi realizada com o conjunto de dados reservado para esse fim, e os resultados foram comparados com as previsões feitas pelos modelos treinados.

O desempenho do modelo foi avaliado com a métrica de acurácia, que é uma medida da proporção de previsões corretas feitas pelo modelo. A acurácia é uma das métricas mais comumente utilizadas para avaliar o desempenho de modelos de aprendizagem de máquina. Ela é definida como a proporção de previsões corretas feitas pelo modelo em relação ao total de previsões (He and Garcia, 2009). Em outras palavras, é a relação entre o número de previsões corretas e o número total de previsões. A acurácia é uma métrica simples e fácil de entender, mas pode ser enganosa em alguns casos, especialmente quando existe desequilíbrio de classe no conjunto de dados (He and Garcia, 2009). Os resultados obtidos dos modelos treinados de CNNs são apresentados na tabela a seguir.

Tabela 2. Resultados de CNNs.

CNN	Configuração.	Acurácia (%)
VGG19	11	88.53
VGG19	12	90.15
MobileNet	11	88.56
MobileNet	12	90.84
InceptionV3	11	87.43
InceptionV3	12	90.93
VGG19	21	90.04
VGG19	22	91.78
MobileNet	21	95.71
MobileNet	22	98.12
InceptionV3	21	90.02
InceptionV3	22	91.40

Todas as CNNs que foram avaliadas conseguiram realizar o procedimento de treinamento sem atingir o valor estipulado na configuração de *patience*, o que indica um aprendizado contínuo. A melhor CNN que obteve o melhor valor de acurácia, foi a arquitetura MobileNet, de configuração 22 que atingiu a acurácia de 98,12%. Embora o VGG19 seja considerado um modelo de referência em




Figura 4. Gráficos de desempenho do melhor modelo.

classificação de imagens e tenha uma arquitetura mais profunda do que o MobileNet e o InceptionV3, isso não garante necessariamente que obterá uma acurácia melhor. Há várias razões pelas quais o MobileNet pode ter obtido uma acurácia melhor nesses resultados específicos.

Uma razão é que o *MobileNet* foi projetado especificamente para ser utilizado em dispositivos móveis, onde a eficiência computacional é crucial. Isso é alcançado através do uso de camadas de profundidade móvel e do uso de camadas de ponto de fusão, que reduzem o número de parâmetros e a complexidade computacional do modelo. Isso pode dar ao *MobileNet* uma vantagem sobre os outros modelos em termos de generalização, ou seja, a capacidade do modelo de fazer previsões precisas em novos conjuntos de dados.

Outra razão pode ser que o conjunto de dados usado para treinar os modelos foi mais adequado para o *MobileNet*. Ele pode ter sido projetado para lidar com imagens semelhantes às presentes no conjunto de dados de treinamento, o que levou a uma melhor performance. A acurácia de uma rede neural na tarefa de classificação binária de imagens varia de acordo com o conjunto de dados e as configurações utilizadas. É possível que as configurações usadas para treinar o *MobileNet* foram mais adequadas para esse conjunto de dados específico e, portanto, levaram a uma melhor performance. Ainda vale ressaltar que os modelos que apresentaram melhor acurácia foram aqueles treinados com imagens pré-processadas, o que comprova a eficiência das técnicas de suporte ao pré-processamento.

Em geral, redes neurais mais profundas e complexas, como a *VGG19*, tendem a ter melhores desempenhos em tarefas de classificação. No entanto, essas redes também tendem a ser mais pesadas e requerem mais recursos computacionais, o que exigirá um hardware com maior poder computacional para oferecer o suporte adequado a tarefa de inspeção de defeitos em PCB. Os gráficos de desempenho do melhor modelo são apresentados na Figura 4.




Figura 5. Imagens classificadas.

Na Figura 4 (eixo *Accuracy*) é apresentado o gráfico da acurácia do modelo em relação ao número de épocas quando empregado os conjuntos de treinamento e validação. Também é mostrado o gráfico de perda (eixo *Cross Entropy* do modelo em relação ao número de épocas quando utilizado os conjuntos de treinamento e validação. Por meio dos gráficos é possível constatar que a acurácia do treinamento e validação estão muito próximas, comportamento também observado no gráfico de perdas o que indicar que o modelo não apresenta *overfitting*. Isso leva crer que o uso das técnicas de *Data Aumentation*, *Dropout* surtiram o efeito desejado de minimizar o problema do *overfitting*.

Também foi possível constatar por meio dos gráficos que durante as épocas 2 e 19 houve uma queda da acurácia e um aumento da perda, isso levar a crê que o conjunto de dados usado para treinamento e validação deve ter algumas imagens que necessitam a correção do rótulo, apesar disso, a acurácia final do modelo de aproximadamente 98,12% indica que a utilização de CNNs para detecção de defeitos em PCB é promissor. A Figura 5 apresentam algumas imagens classificadas pelo modelo MobileNet. É possível notar que todos os recortes de imagens foram classificados corretamente, dentre eles, alguns defeitos detectados de um módulo de memória.

Considerando os resultados apresentados na Tabela 2, A MobileNet configuração 22 apresentou uma acurácia superior do que as acurácias apresentadas por Iwahori (2017) e Kim et al. (2021).

6. CONCLUSÃO

O objetivo principal deste trabalho consistiu em realizar um estudo visando avaliar o uso de CNNs na detecção de defeitos físicos em imagens de PCBs. Para isso, foi criada um conjunto de dados com 4804 imagens classificadas em duas classes: Good e Bad. A partir dessa etapa, foram treinadas arquiteturas canônicas de CNNs amplamente utilizadas na tarefa de Visão Computacional implementada por meio de classificação binária de imagens. Nesse estudo foram avaliadas as CNNs: VGG19, MobileNet e InceptionV3. No treinamento dessas CNNs foram usados diferentes configurações de parâmetros e hiperparâmetros com um total de 12 variações das redes.

A partir deste estudo, foi possível concluir que a CNN MobileNet com a configuração 22 foi a melhor arquitetura

para a detecção de defeitos físicos em PCB, apresentando uma acurácia de aproximadamente 98,12%. Estes resultados apresentados são significativos para o desenvolvimento de sistemas de detecção de defeitos automatizados e podem contribuir para aplicar a Indústria 4.0. Sugerimos futuros estudos para aprimorar a arquitetura da MobileNet, e aplicar outros filtros de imagem eliminar ruídos como o filtro Gaussiano e a binarização de imagem a fim de aumentar a acurácia do sistema de detecção de defeitos. Além disso, avaliar novas CNNs que estão sendo lançadas, como ResNetxt50 e EfficientNetB50 visando melhorar ainda mais o desempenho do sistema. Vale ressaltar que o problema de detecção de defeitos físicos em imagens de é relevante para o cenário atual da indústria inteligente também conhecida como Indústria 4.0.

AGRADECIMENTOS

Os autores agradecem o apoio da Universidade do Estado do Amazonas - UEA, da Escola Superior de Tecnologia - EST e do Laboratório de Automação Inteligente e Controle de Processos - LAICP.

REFERÊNCIAS

- Arinez, J.F., Chang, Q., Gao, R.X., Xu, C., and Zhang, J. (2020). Artificial Intelligence in Advanced Manufacturing: Current Status and Future Outlook. *Journal of Manufacturing Science and Engineering*, 142(11). doi:10.1115/1.4047855. URL <https://doi.org/10.1115/1.4047855>. 110804.
- Arun Pandian, J., Geetharamani, G., and Annette, B. (2019). Data augmentation on plant leaf disease image dataset using image manipulation and deep learning techniques. 199–204. doi:10.1109/IACC48062.2019.8971580.
- Gal, Y. and Ghahramani, Z. (2016). Dropout as a bayesian approximation: Representing model uncertainty in deep learning. 1050–1059.
- He, H. and Garcia, E.A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9), 1263–1284. doi:10.1109/TKDE.2008.239.
- Hou, W., Wei, Y., Guo, J., Jin, Y., and Zhu, C. (2017). Automatic detection of welding defects using deep neural network. *Journal of Physics: Conference Series*, 933(1), 012006. doi:10.1088/1742-6596/933/1/012006. URL <https://dx.doi.org/10.1088/1742-6596/933/1/012006>.
- Howard, A.G., Zhu, M., Chen, B., Kalenichenko, D., Wang, W., Weyand, T., Andreetto, M., and Adam, H. (2017). Mobilenets: Efficient convolutional neural networks for mobile vision applications. *CoRR*, abs/1704.04861. URL <http://arxiv.org/abs/1704.04861>.
- Iwahori, Y. (2017). Defect detection and classification of electronic circuit boards using keypoint extraction and cnn features.
- Kim, J., Ko, J., Choi, H., and Kim, H. (2021). Printed circuit board defect detection using deep learning via a skip-connected convolutional autoencoder. *Sensors*, 21(15). doi:10.3390/s21154968. URL <https://www.mdpi.com/1424-8220/21/15/4968>.
- Kim, M. and Bae, H.J. (2020). Data augmentation techniques for deep learning-based medical image analyses. *Journal of the Korean Society of Radiology*, 81(6). doi:10.3348/jksr.2020.0158.
- Kingma, D.P. and Ba, J. (2017). Adam: A method for stochastic optimization.
- Maleki, F., Muthukrishnan, N., Ovens, K., Reinhold, C., and Forghani, R. (2020). Machine learning algorithm validation: From essentials to advanced applications and implications for regulatory certification and deployment. *Neuroimaging Clinics of North America*, 30(4), 433–445. doi:<https://doi.org/10.1016/j.nic.2020.08.004>. URL <https://www.sciencedirect.com/science/article/pii/S1052514920300599>. Machine Learning and Other Artificial Intelligence Applications.
- Pang, B., Nijkamp, E., and Wu, Y.N. (2020). Deep learning with tensorflow: A review. *Journal of Educational and Behavioral Statistics*, 45(2), 227–248. doi:10.3102/1076998619872761. URL <https://doi.org/10.3102/1076998619872761>.
- Qi, S., Yang, J., and Zhong, Z. (2020). A review on industrial surface defect detection based on deep learning technology. 24–30. doi:10.1145/3426826.3426832. URL <https://doi.org/10.1145/3426826.3426832>.
- Reinhard, E., Stark, M., Shirley, P., and Ferwerda, J. (2002). Photographic tone reproduction for digital images. *ACM Trans. Graph.*, 21(3), 267–276. doi:10.1145/566654.566575. URL <https://doi.org/10.1145/566654.566575>.
- Shen, D., Wu, G., and Suk, H.I. (2017). Deep learning in medical image analysis. *Annual Review of Biomedical Engineering*, 19(1), 221–248. doi:10.1146/annurev-bioeng-071516-044442. URL <https://doi.org/10.1146/annurev-bioeng-071516-044442>. PMID: 28301734.
- Shiina, T., Iwahori, Y., and Kijsirikul, B. (2018). Defect classification of electronic circuit board using multi-input convolutional neural network. *International Journal of Computer & Software Engineering*.
- Simonyan, K. and Zisserman, A. (2015). Very deep convolutional networks for large-scale image recognition.
- Song, S., Jing, J., Huang, Y., and Shi, M. (2021). Efficientdet for fabric defect detection based on edge computing. *Journal of Engineered Fibers and Fabrics*, 16, 15589250211008346. doi:10.1177/15589250211008346. URL <https://doi.org/10.1177/15589250211008346>.
- Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., and Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. *J. Mach. Learn. Res.*, 15(1), 1929–1958.
- Szegedy, C., Vanhoucke, V., Ioffe, S., Shlens, J., and Wojna, Z. (2016). Rethinking the inception architecture for computer vision. 2818–2826. doi:10.1109/CVPR.2016.308.
- Tieleman, T., Hinton, G., et al. (2012). Lecture 6.5-rmsprop: Divide the gradient by a running average of its recent magnitude. *COURSERA: Neural networks for machine learning*, 4(2), 26–31.
- Xin, H., Chen, Z., and Wang, B. (2021). Pcb electronic component defect detection method based on improved yolov4 algorithm. *Journal of Physics: Conference Series*, 1827(1), 012167. doi:10.1088/1742-6596/1827/1/012167. URL <https://dx.doi.org/10.1088/1742-6596/1827/1/012167>.